

武汉大学

本科毕业论文（设计）

基于 LoRA 技术的特定风格视频生成  
模型研究

姓 名：程 森  
学 号：2022302111084  
专 业：计算机科学与技术  
学 院：计算机学院  
指导教师：武 宇 教 授

二〇二六年四月

## 原创性声明

本人郑重声明：所呈交的论文（设计），是本人在指导教师的指导下，严格按照学校和学院有关规定完成的。除文中已经标明引用的内容外，本论文（设计）不包含任何其他个人或集体已发表及撰写的研究成果。对本论文（设计）做出贡献的个人和集体，均已在文中以明确方式标明。本人承诺在论文（设计）工作过程中没有伪造数据等行为。若在本论文（设计）中有侵犯任何方面知识产权的行为，由本人承担相应的法律责任。

作者签名：程森

指导教师签名：武宇

日期：2026 年 4 月 15 日

## 版权使用授权书

本人完全了解武汉大学有权保留并向有关部门或机构送交本论文（设计）的复印件和电子版，允许本论文（设计）被查阅和借阅。本人授权武汉大学将本论文的全部或部分内容编入有关数据进行检索和传播，可以采用影印、缩印或扫描等复制手段保存和汇编本论文（设计）。

作者签名：程森

指导教师签名：武宇

日期：2026 年 4 月 15 日

# 摘要

随着生成式人工智能的发展,如何以较低成本生成具有特定艺术风格且质量稳定的视频,已经成为当前研究中的一个重要问题。传统视频生成模型往往依赖较高算力和全参数微调,训练开销大,同时在保持目标风格的过程中还容易破坏时序一致性。针对这一问题,本文提出了一种基于 LoRA (Low-Rank Adaptation) 技术的特定风格视频生成研究框架,尝试在有限算力和有限样本条件下,探索一条兼顾风格表达与工程可行性的技术路线。

本文首先梳理了扩散模型与潜空间生成技术的基本原理,分析了 LoRA 参数高效微调方法在特定风格适配中的适用性。在数据准备阶段,通过对目标动画风格图像进行规范化预处理与自动标注,构建了包含 810 张样本的吉卜力动画风格数据集。在模型训练阶段,本文以 Stable Diffusion 1.5 为核心底模设计 LoRA 注入策略,并比较了不同底模 (StorybookRedmond、Counterfeit-V3.0) 在相近训练强度下的表现差异。实验结果表明,加载 LoRA 适配器后,模型在颜色分布、线条强度和场景组织上均产生了稳定且可观测的风格偏移;具有较强视觉先验的底模能够进一步增强风格迁移强度,但同时也需要在风格纯度与内容保真之间做出权衡。

在视频验证阶段,本文构建了递推式短视频生成原型,并引入无参考时序一致性评估指标。量化分析表明,加载风格 LoRA 后,视频的相邻帧像素平均绝对差 (MAD) 和边缘变化平均绝对差 (MED) 均有所下降,说明图像阶段获得的风格能力能够在一定程度上迁移到连续帧中。针对实验中暴露出的亮度稳定性 (LS) 波动问题,本文进一步分析了其形成原因,并提出了后续引入显式运动模块与结构控制技术的改进方向。本文的研究为独立创作者和中小团队开展个性化视频内容生产提供了可复用的技术参考。

**关键词:** 特定风格; LoRA 技术; 视频生成; 扩散模型; 参数高效微调

# ABSTRACT

With the development of Artificial Intelligence Generated Content (AIGC), low-cost generation of high-quality videos with specific artistic styles has become an important research topic. Traditional video generation models usually depend on substantial computational resources and full-parameter fine-tuning, while still struggling to maintain both stylistic consistency and temporal stability. To address this issue, this thesis proposes a research framework for specific-style video generation based on LoRA (Low-Rank Adaptation), aiming to explore a technical route that balances style expression and engineering feasibility under limited computational resources and sample sizes.

The thesis first reviews the basic principles of Diffusion Models and Latent Diffusion frameworks, and analyzes the suitability of LoRA parameter-efficient fine-tuning for specific style adaptation. In the data preparation stage, a stylized dataset containing 810 samples was built through standardized preprocessing and automated captioning of target animation images. At the model training stage, Stable Diffusion 1.5 was adopted as the core base model, a LoRA injection strategy was designed, and the performance of different base models (StorybookRedmond and Counterfeit-V3.0) was compared under similar training intensities. Experimental results show that loading LoRA adapters leads to stable and observable style shifts in color distribution, line intensity, and scene organization. Base models with stronger visual priors can further strengthen style transfer, but they also require a trade-off between style purity and content fidelity.

In the video validation stage, a recursive short-video generation prototype was constructed, and no-reference temporal consistency metrics were introduced. Quantitative analysis indicates that after loading the style LoRA, both the Mean Absolute Difference (MAD) and the Mean Edge Difference (MED) of adjacent frames decreased, showing that the learned style capability can be transferred to continuous frames to a certain extent. To address the Brightness Standard Deviation (LS) fluctuations observed in the experiments, this thesis further analyzes the underlying causes and proposes future improvements involving explicit motion modules and structural control techniques. The

study provides a reusable technical reference for independent creators and small teams engaged in personalized video content production.

**Keywords:** Specific Style; LoRA Technology; Video Generation; Diffusion Models; Parameter-Efficient Fine-Tuning

# 目 录

|                                     |    |
|-------------------------------------|----|
| 摘 要 .....                           | I  |
| ABSTRACT .....                      | II |
| 1 绪论 .....                          | 1  |
| 1.1 研究背景与意义 .....                   | 1  |
| 1.2 国内外研究现状 .....                   | 2  |
| 1.3 论文研究内容 .....                    | 4  |
| 1.4 论文章节安排 .....                    | 5  |
| 1.5 本章小结 .....                      | 5  |
| 2 相关理论与关键技术基础 .....                 | 7  |
| 2.1 扩散模型基本原理 .....                  | 7  |
| 2.1.1 前向扩散过程 .....                  | 7  |
| 2.1.2 反向去噪过程与训练目标 .....             | 7  |
| 2.2 潜空间扩散模型与 Stable Diffusion ..... | 8  |
| 2.2.1 潜空间表示与 VAE 压缩机制 .....         | 8  |
| 2.2.2 U-Net 去噪网络与交叉注意力条件注入 .....    | 9  |
| 2.3 LoRA 参数高效微调技术 .....             | 9  |
| 2.3.1 LoRA 的基本原理 .....              | 9  |
| 2.3.2 LoRA 在扩散模型中的应用方式 .....        | 10 |
| 2.4 视觉—语言预训练与数据标注技术 .....           | 11 |
| 2.4.1 CLIP 模型 .....                 | 11 |
| 2.4.2 BLIP 与 BLIP-2 自动标注机制 .....    | 11 |
| 2.5 视频生成与时序建模技术 .....               | 12 |
| 2.5.1 基于扩散模型的视频生成 .....             | 12 |

|          |                                 |           |
|----------|---------------------------------|-----------|
| 2.5.2    | AnimateDiff 运动模块                | 13        |
| 2.6      | 可控生成与结构约束技术                     | 13        |
| 2.6.1    | ControlNet 条件控制机制               | 13        |
| 2.6.2    | 风格保持与主体一致性问题                    | 14        |
| 2.7      | 本章小结                            | 14        |
| <b>3</b> | <b>基于 LoRA 的特定风格视频生成方案设计与实现</b> | <b>15</b> |
| 3.1      | 任务分析与总体架构设计                     | 15        |
| 3.1.1    | 研究目标与输入输出定义                     | 15        |
| 3.1.2    | 系统整体流程设计                        | 15        |
| 3.2      | 数据集构建与预处理模块设计                   | 16        |
| 3.2.1    | 风格图像数据集构建                       | 16        |
| 3.2.2    | 图像数据预处理与元数据导出                   | 17        |
| 3.2.3    | 视频帧数据预处理设计                      | 17        |
| 3.3      | 基于 LoRA 的风格学习模型设计               | 18        |
| 3.3.1    | 训练底模与条件输入设计                     | 18        |
| 3.3.2    | LoRA 注入策略与参数配置                  | 18        |
| 3.3.3    | 训练目标与优化流程                       | 19        |
| 3.4      | 生成与评估模块实现                       | 19        |
| 3.4.1    | 单图推理与基线对比实现                     | 19        |
| 3.4.2    | 短视频生成原型实现                       | 20        |
| 3.4.3    | 时序一致性评价指标设计                     | 21        |
| 3.5      | 关键算法描述                          | 22        |
| 3.5.1    | 图像预处理算法                         | 22        |
| 3.5.2    | LoRA 训练算法                       | 22        |
| 3.5.3    | 视频递推生成算法                        | 23        |
| 3.6      | 本章小结                            | 23        |

|                                       |           |
|---------------------------------------|-----------|
| <b>4 实验与结果分析</b>                      | <b>25</b> |
| 4.1 实验设置                              | 25        |
| 4.1.1 实验目标与验证思路                       | 25        |
| 4.1.2 数据集与预处理结果                       | 25        |
| 4.1.3 实验环境与参数配置                       | 26        |
| 4.1.4 评价指标与结果呈现方式                     | 28        |
| 4.2 图像风格学习实验结果分析                      | 28        |
| 4.2.1 基于 Stable Diffusion 1.5 的短训验证结果 | 28        |
| 4.2.2 caption 组织增强实验分析                | 30        |
| 4.2.3 不同底模长训结果比较                      | 31        |
| 4.2.4 图像阶段结果归纳                        | 33        |
| 4.3 视频原型实验与时序一致性分析                    | 34        |
| 4.3.1 视频原型实验方案                        | 34        |
| 4.3.2 时序一致性定量结果                       | 34        |
| 4.3.3 视频结果的定性观察与局限                    | 35        |
| 4.4 实验讨论                              | 36        |
| 4.4.1 风格学习有效性讨论                       | 36        |
| 4.4.2 指标与主观观感差异的原因分析                  | 36        |
| 4.4.3 当前方案的局限与后续优化方向                  | 37        |
| 4.5 本章小结                              | 38        |
| <b>5 总结与展望</b>                        | <b>39</b> |
| 5.1 工作总结                              | 39        |
| 5.2 研究展望                              | 40        |
| <b>参考文献</b>                           | <b>41</b> |
| <b>致谢</b>                             | <b>46</b> |



# 1 绪论

## 1.1 研究背景与意义

随着人工智能生成内容技术的快速发展，基于扩散模型<sup>[1]</sup>的图像生成方法已经逐渐成熟，研究重心也开始由静态图像扩展到视频生成。与图像生成相比，视频生成不仅要求模型具备较强的单帧细节表达能力，还要求生成结果在时间维度上保持连续、稳定和自然，因此其建模难度明显更高，这也使视频生成成为当前生成式人工智能领域的重要研究方向<sup>[2]</sup>。在动画制作、短视频创作、数字文旅展示、游戏资产生产和虚拟内容传播等场景中，如果能够以较低门槛生成具有明确艺术风格的视频内容，将具有较高的应用价值。

目前主流视频生成模型虽然在通用场景下已经取得较好效果，但在特定风格定制任务中仍然面临两个突出问题。其一，视频扩散模型参数规模较大，如果直接采用全参数微调，不仅训练成本高，而且对显存、训练时长和数据规模的要求都较为苛刻，普通研究环境和消费级硬件往往难以长期支撑；其二，风格迁移过程容易破坏视频原有的时序一致性，使生成结果出现闪烁、动作变形或主体不稳定等现象，导致生成视频难以同时兼顾风格表达和连续观感。因此，如何在有限算力条件下实现高质量、可控且时序连贯的特定风格视频生成，成为一个值得深入研究的问题。

LoRA<sup>[3]</sup>是一种典型的参数高效微调方法，它通过冻结预训练底模的大部分参数，仅在关键模块中引入少量可训练的低秩矩阵，从而显著降低训练成本和部署门槛。在图像生成领域，LoRA 已经被广泛用于风格迁移、主体定制和轻量微调等任务<sup>[4]</sup>；如果将这一思路进一步扩展到视频生成场景，一方面可以降低模型适配过程中的资源消耗，另一方面也为分析空间风格建模与时间动态建模之间的平衡关系提供了一条可行路径。围绕这一思路展开研究，有助于形成一种低成本、高效率的特定风格视频生成方案。

结合本课题的实际条件与研究目标，本文不以从零训练大型视频基础模型为目标，而是围绕“低成本完成特定风格学习，并验证其向视频阶段迁移的可行性”展开研究。通过构建特定风格数据集、设计基于扩散模型的 LoRA 微调方案、比较不同底模先验的影响，并将图像阶段获得的风格能力扩展到短视频原型

验证，本文试图回答一个具有现实意义的问题：在有限算力和有限数据条件下，是否能够建立一条兼顾风格表达、实验可复现性和工程可实施性的特定风格视频生成路线。

本文所关注的特定风格视频生成任务，其基本输入、关键处理环节与预期输出形式可概括为图1-1所示。




图 1-1 特定风格视频生成任务示意图

从理论层面看，本课题有助于分析 LoRA 在视频扩散模型中的作用机制，尤其是其对空间注意力层和时间注意力层可能产生的不同影响，从而为参数高效微调方法在高维时空生成任务中的应用提供参考。从实践层面看，本课题致力于在较低算力条件下实现特定风格的视频生成流程，有望为独立动画创作、个性化内容生产和中小团队智能视频制作提供可复用的技术方案，具有较强的现实意义。

1.2 国内外研究现状

国外关于视频生成的研究起步较早，其技术路线经历了从生成对抗网络向扩散模型的明显转移。早期方法主要关注短时序、低分辨率视频的生成<sup>[5]</sup>，随着扩散模型在图像任务中表现出更稳定的训练特性和更高的生成质量<sup>[6]</sup>，研究重心逐步转向基于扩散过程的视频生成框架。近年来，Stable Video Diffusion<sup>[7]</sup>、Lumiere<sup>[8]</sup>等代表性工作在长时序建模、画面清晰度提升和时空联合结构设计等方面取得了较大进展，也为后续风格迁移和参数高效适配研究提供了更稳固的基础。

在参数高效微调方面，LoRA 最初广泛应用于大语言模型领域<sup>[3]</sup>，随后被迅速迁移到视觉生成任务中<sup>[9-10]</sup>。国外研究者围绕 Few-Shot 和 One-Shot 场景开展了大量探索，尝试在较少样本条件下完成风格迁移、主体保持和个性化生成等任

务。相关研究表明, LoRA 在静态图像风格微调中具有明显优势, 但在视频任务中, 如何处理时间注意力层, 以及如何在保持动作连贯性的同时注入特定风格, 仍然是尚未完全解决的问题<sup>[11]</sup>。

国内研究更强调视频生成技术的工程落地与可控生成能力的提升。以 AnimateDiff<sup>[12]</sup>、VideoCrafter<sup>[13]</sup>等为代表的工作, 一方面从运动模块建模、视频高分辨率生成和时序先验复用等方向推动了视频生成技术的发展, 另一方面也逐渐形成了风格模块与运动模块解耦的工程化思路。一些研究通过解耦风格模块与运动模块来增强视频生成的灵活性; 另一些研究则引入 ControlNet<sup>[14]</sup>、ReferenceNet<sup>[15]</sup>等控制机制, 用于提升角色一致性、结构可控性和动作稳定性。这些成果表明, 国内在视频生成系统化实现、开源复现和应用适配方面已经积累了较为扎实的经验。

综合国内外研究现状可以看出, 当前特定风格视频生成大致呈现出三方面趋势。第一, 模型适配方式正由粗粒度统一微调转向更细粒度的模块化控制, 即分别考虑空间外观建模与时间动态建模<sup>[16]</sup>。第二, 风格生成不再局限于单一适配器, 而是逐步发展为多 LoRA 组合、结构约束与参考图引导等联合方案, 以同时兼顾画质、风格强度和主体稳定性<sup>[17-18]</sup>。第三, 研究重点正在从“能否生成视频”转向“如何生成可控、可复现且更符合目标风格的视频”, 这也意味着评价体系 and 实验流程在不断完善<sup>[19-20]</sup>。

尽管已有研究为本课题提供了较多基础, 但仍存在两个与本文高度相关的空白。其一, 面向小规模特定风格数据集的轻量化个性化学习虽然已经显示出可行性<sup>[21]</sup>, 但围绕完整实验流程、参数组织和结果解释的相对统一范式仍然不足, 尤其是在学生研究环境中, 往往很难兼顾训练成本与结果可解释性。其二, 许多工作更关注通用视频生成能力, 而对图像域风格学习如何向视频阶段迁移讨论不足<sup>[22]</sup>。本文正是在这一背景下展开, 希望通过图像阶段的 LoRA 风格学习、底模替换比较和短视频原型验证, 为特定风格视频生成提供一条更具可操作性的研究路线。

### 1.3 论文研究内容

围绕基于 LoRA 技术的特定风格视频生成模型这一主题，本文首先从理论与方法层面对扩散模型<sup>[1]</sup>、潜空间生成<sup>[4]</sup>、参数高效微调<sup>[3]</sup>以及视频时序建模<sup>[12-13]</sup>等相关技术进行梳理，在此基础上分析 LoRA 适用于视频生成任务的原因，并明确其在训练成本、风格迁移能力和可部署性方面的优势。通过理论分析与技术比较，为后续实验方案设计提供支撑。

在数据层面，本文围绕目标风格构建了较为规范的数据处理流程。图像阶段对风格样本进行整理、筛选、裁剪、尺寸统一和文本描述对齐<sup>[23]</sup>，形成可直接用于 LoRA 训练的图文配对数据；视频阶段则对片段样本进行帧序列导出、样本划分和一致性检查，为后续短视频原型实验提供基础。与单纯堆叠素材不同，本文更强调训练数据在风格表达、语义描述<sup>[24]</sup>和实验可复现性之间的平衡关系。

在模型与实验层面，本文以 Stable Diffusion 系列模型为基础构建 LoRA 风格学习方案，重点研究 LoRA 在 U-Net 注意力模块<sup>[25-26]</sup>中的注入方式，以及训练步数、学习率、LoRA 秩、caption 组织方式等因素对生成结果的影响。除以 Stable Diffusion 1.5 为主线完成短训与长训验证外，本文还进一步引入 StorybookRedmond 和 Counterfeit-V3.0 等具有不同先验风格的底模进行替换实验，以比较不同预训练底模在特定风格适配中的表现；这类围绕特定风格开展轻量参数调整的思路，与 StyleDrop<sup>[27]</sup>等工作关注的问题具有一致性。

在结果验证层面，本文采用先图像、后视频的渐进式研究路线。图像阶段通过单图推理、批量提示词对比、差异可视化和统计指标分析<sup>[28]</sup>来判断 LoRA 是否成功学习到目标风格；视频阶段则在图像 LoRA 的基础上构建递推式短视频生成原型，并从相邻帧差异、边缘稳定性和亮度波动<sup>[29-30]</sup>等角度评估风格能力向连续帧迁移的效果。这一路线既符合本课题的现实算力条件，也能够形成较完整的实验闭环。

归纳而言，本文的研究内容可以概括为四个方面：一是梳理特定风格视频生成相关理论与技术；二是构建面向风格学习的数据处理与训练流程；三是设计并验证基于 LoRA 的多底模风格微调方案；四是通过图像和短视频实验分析其有效性、局限性及进一步优化方向。上述内容共同构成了全文的研究主线。

## 1.4 论文章节安排

基于上述研究内容，全文章节安排如下：

第一章，绪论：主要介绍本课题的研究背景与意义，梳理国内外相关研究现状，明确本文的研究内容、技术路线以及整体章节安排。

第二章，相关理论与关键技术基础：围绕本文研究所依赖的理论基础与关键方法展开介绍，重点阐述扩散模型、潜空间扩散框架、LoRA 参数高效微调、视觉—语言标注技术、视频生成与结构控制等相关内容。

第三章，基于 LoRA 的特定风格视频生成方案设计与实现：围绕特定风格视频生成任务的实现流程，对数据集构建、预处理模块、LoRA 风格学习模型设计、图像推理与短视频原型生成等内容进行说明。

第四章，实验与结果分析：针对图像风格学习实验、不同底模替换实验以及视频原型验证实验展开分析，并结合定量指标与定性结果讨论模型的风格迁移效果、内容保真表现和时序一致性特点。

第五章，总结与展望：对本文的研究工作进行归纳，总结当前方案的主要结论，并结合实验中暴露出的问题对后续研究方向进行展望。

论文整体结构及各章节之间的逻辑关系可进一步概括为图1-2所示。

## 1.5 本章小结

本章围绕论文研究工作的总体背景展开论述，分析了特定风格视频生成任务在当前生成式人工智能发展背景下的研究价值，梳理了国内外相关研究的主要进展与发展趋势，并明确了本文的研究内容与章节安排。通过本章的讨论可以看出，基于 LoRA 的参数高效微调方法为解决特定风格视频生成中的高成本训练与时序一致性问题提供了可行思路，也为后续理论分析、系统设计与实验验证奠定了整体框架。




图 1-2 论文章节安排示意图

## 2 相关理论与关键技术基础

### 2.1 扩散模型基本原理

#### 2.1.1 前向扩散过程

扩散模型是一类通过逐步加噪与逐步去噪完成数据建模的生成模型。Ho 等人在 Denoising Diffusion Probabilistic Models<sup>[1]</sup>中将生成过程描述为两个方向相反的马尔可夫链：在前向扩散过程中，模型按照预先设定的噪声调度策略，向真实样本逐步注入高斯噪声，使原始数据从清晰图像逐渐演化为近似各向同性高斯分布；在反向过程中，再由神经网络学习如何从噪声中逐步恢复目标样本。与依赖对抗训练的传统 GAN 相比，扩散模型训练更稳定、模式覆盖能力更强，因此逐渐成为当前图像与视频生成任务的主流框架。

在数学形式上，设原始样本为  $x_0$ ，扩散模型通过一系列时间步  $t = 1, 2, \dots, T$  将样本逐步变换为  $x_t$ 。每一步前向扩散都可以表示为在上一时刻样本上加入少量高斯噪声，因此随着时间步增加，样本中的语义结构与细节信息会被持续削弱，最终得到近似纯噪声的  $x_T$ 。这一过程本身不需要学习参数，它的作用在于把复杂的数据分布转化为更容易处理的噪声分布，从而为反向生成建立统一的概率路径。对于图像生成任务而言，前向扩散可以看作是一个从有意义图像到无结构噪声的连续退化过程。

#### 2.1.2 反向去噪过程与训练目标

扩散模型真正需要学习的是反向去噪过程，即在给定当前噪声样本  $x_t$  的条件下，预测其在上一时刻  $x_{t-1}$  的分布，逐步将噪声恢复为符合目标数据分布的样本。由于直接建模完整的反向分布较为困难，DDPM<sup>[1]</sup>将其近似为高斯分布，并利用神经网络预测噪声项或等价变量，从而实现逐步去噪。在实际训练中，通常将目标简化为最小化模型预测噪声与真实噪声之间的均方误差，这种训练方式既保留了理论上的变分推断基础，也显著提高了实现效率。因此，在 Stable Diffusion 等后续模型中，扩散模型通常表现为一个在不同时间步估计噪声的条件生成器。

在文本条件生成任务中，扩散模型还需要引入条件信息来控制生成方向。

Classifier-Free Guidance<sup>[31]</sup>进一步提出，无需额外训练分类器，就可以通过同时学习有条件与无条件两个分支，在采样阶段对二者的预测结果进行线性组合，从而在样本多样性和语义一致性之间取得平衡。该方法已经成为现代文生图模型中的标准采样策略。对于本研究而言，提示词、负向提示词以及 guidance scale 等参数本质上都与这一引导机制密切相关，它决定了生成结果是更强调文本约束，还是保留更多底模的自由生成能力。

扩散模型中前向加噪与反向去噪之间的对应关系如图2-1所示。




图 2-1 扩散模型的前向与反向扩散过程

## 2.2 潜空间扩散模型与 Stable Diffusion

### 2.2.1 潜空间表示与 VAE 压缩机制

早期扩散模型大多直接在像素空间中进行加噪与去噪，这种方式虽然能够取得较高的生成质量，但在高分辨率图像场景下会带来很高的显存和计算开销。Rombach 等人在 Latent Diffusion Models<sup>[4]</sup>中提出，将扩散过程从像素空间迁移到低维潜空间中进行，即先使用自编码器将图像压缩为更紧凑的潜变量表示，再在潜变量上完成扩散建模，最后通过解码器重建高分辨率图像。这一思路使扩散模型在细节保真和训练成本之间取得了较好的平衡，也是 Stable Diffusion 系列模型能够在有限算力条件下广泛应用的重要原因。



在潜空间扩散框架中，变分自编码器承担感知压缩和图像重建的任务。编码器负责将原始图像映射到低维潜变量  $z$ ，解码器则将生成得到的潜变量重新还原为可视图像<sup>[4]</sup>。由于潜空间维度远小于原始像素空间，模型在训练时不必直接处理冗余像素细节，而是集中学习更高层次的语义结构与纹理模式。对本研究而言，使用 Stable Diffusion v1.5 作为底模，本质上是在继承 LDM 架构优势的基础上开展后续风格学习，因此理解潜空间建模机制，对于分析分辨率设置、显存占用与训练速度之间的关系具有重要意义。

### 2.2.2 U-Net 去噪网络与交叉注意力条件注入

在 Stable Diffusion 中，负责执行去噪任务的核心网络通常是 U-Net。U-Net 采用编码器—解码器对称结构，通过下采样逐步提取全局语义信息，再通过上采样逐步恢复空间分辨率，并借助跳跃连接将浅层细节与深层语义进行融合。扩散模型在每一个时间步都会将当前潜变量、时间步嵌入以及文本条件共同输入 U-Net，使网络能够在不同噪声强度下学习如何恢复图像结构<sup>[4]</sup>。这种多尺度特征融合能力使 U-Net 非常适合承担扩散去噪器的角色，也使其成为后续 LoRA 插入的主要位置。

为了让文本提示词真正影响生成结果，LDM<sup>[4]</sup>在 U-Net 中引入了交叉注意力机制。文本编码器首先将提示词转换为一组语义嵌入向量，随后这些向量通过交叉注意力与图像潜变量特征发生交互，从而把语言信息注入图像生成过程。这一设计使模型不再只是无条件地从噪声恢复图像，而是可以在每个去噪阶段持续参考文本语义，逐步生成更符合提示词要求的结果。本研究中的吉卜力风格 LoRA 训练，本质上也是围绕这一条件生成框架展开：一方面保持底模原有的文本到图像映射能力，另一方面通过少量可训练参数改变注意力层对特定风格特征的响应。

## 2.3 LoRA 参数高效微调技术

### 2.3.1 LoRA 的基本原理

LoRA 是一种典型的参数高效微调方法，其核心思想是：在不直接更新原始大模型权重的前提下，用两个低秩矩阵近似表示权重更新量。Hu 等人<sup>[3]</sup>指出，许多大模型在下游任务适配时，真正有效的权重变化往往具有较低的内在秩，因此

没有必要对全部参数进行全量更新。基于这一认识，LoRA 将某一层的权重更新写为  $\Delta W = BA$ ，其中  $A$  和  $B$  的秩远小于原始权重矩阵的维度，训练时只优化这两个小矩阵，而冻结底模原有参数。这样既能显著减少训练参数量，也不会改变原始模型的主体结构。

LoRA 与常规全参数微调在参数更新范围和训练代价上的差异，可由图2-2进一步说明。




图 2-2 LoRA 与常规微调的原理对比

LoRA 的优势主要体现在三个方面。首先，它大幅降低了显存需求与训练成本，使大模型在消费级显卡上的定制训练成为可能；其次，LoRA 训练得到的适配器文件体积较小，便于存储、切换和复用；最后，由于原始底模权重保持不变，多个不同风格或任务的 LoRA 可以在同一底模上独立训练并灵活加载<sup>[3]</sup>。对于毕业设计这类需要在有限周期内完成多轮实验验证的任务而言，LoRA 具有较高的实用性。它使研究者能够把更多精力放在数据集选择、提示词设计、训练步数控制和风格效果分析上，而不必长期受制于全参数微调带来的高昂资源成本。

### 2.3.2 LoRA 在扩散模型中的应用方式

虽然 LoRA 最初提出于大语言模型场景，但其思想同样适用于扩散模型中的线性映射层，尤其是自注意力层和交叉注意力层中的投影矩阵。对于 Stable Diffusion 这类模型而言，风格、主体特征以及文本响应能力在很大程度上都通过注意力机制进行组织，因此将 LoRA 注入到 query、key、value 或输出投影层，

能够以较小代价改变模型对视觉风格特征和语义条件的表达方式。目前社区中广泛采用的 SD-LoRA 方案<sup>[3-4]</sup>，正是基于这一技术路线形成的。

在本研究的实现中，LoRA 主要承担特定风格适配器的角色。训练时冻结底模的 VAE、文本编码器和大部分 U-Net 参数，仅对注入的低秩矩阵进行更新，使模型逐步学习目标风格数据中的颜色分布、画面纹理、场景构图与笔触特征。由于训练参数较少，研究者可以通过调节 rank、学习率、训练步数等超参数，快速比较不同实验配置对生成结果的影响。进一步地，当 LoRA 与视频生成或结构控制模块结合时，它还可以作为一种可插拔的风格组件，与运动模块、ControlNet 等机制形成协同，这也是本研究后续视频阶段实验的重要理论基础。

## 2.4 视觉—语言预训练与数据标注技术

### 2.4.1 CLIP 模型

CLIP<sup>[23]</sup>是当前视觉—语言预训练领域的代表性工作之一。Radford 等人通过对大规模图文对数据进行对比学习，使图像编码器和文本编码器在同一嵌入空间中完成对齐，从而让模型能够学习图像内容与自然语言描述之间的对应关系。与仅面向固定类别的传统图像分类模型不同，CLIP 利用自然语言作为监督信号，使视觉模型具备更强的开放词汇理解能力和跨任务迁移能力。这种能力对于生成模型尤为重要，因为文生图任务本身就依赖文本条件与视觉语义之间的有效对应。

在扩散模型生态中，CLIP 的作用主要体现在两个方面。其一，它可以作为文本—图像一致性评估工具，用于衡量生成图像是否与给定提示词相匹配；其二，它也可以参与数据筛选、图文检索和风格样本组织，帮助提升训练数据的语义质量<sup>[23]</sup>。对于本研究而言，CLIP 相关思想有助于理解高质量 caption 为何对 LoRA 风格训练如此重要：如果文本描述无法准确概括样本中的场景、主体和艺术风格特征，那么模型在学习时就难以建立稳定的文本—图像映射关系，最终会影响生成阶段的可控性与复现性。

### 2.4.2 BLIP 与 BLIP-2 自动标注机制

仅依靠原始互联网图文对进行训练，往往会受到数据噪声较多、标注不精确等问题影响。BLIP<sup>[32]</sup>提出通过“生成伪标题 + 过滤噪声样本”的方式，对大规

模图文数据进行自举式改进，使模型同时具备视觉理解与文本生成能力。这一机制的价值在于，它不仅能够完成图文检索、视觉问答等理解任务，还能生成图像描述，因此非常适合作为数据预处理阶段的自动 caption 工具。对于风格学习任务而言，BLIP 能够帮助研究者为样本补充更完整的场景、主体和风格描述，从而提高训练样本的文本质量。

BLIP-2<sup>[33]</sup> 进一步提出，在冻结视觉编码器与大语言模型的前提下，通过轻量级 Querying Transformer 桥接视觉特征与语言生成过程，从而以更低的训练代价获得较强的图文理解与生成能力。相比端到端训练大规模视觉语言模型，BLIP-2 的实现方式更高效，也更适合在实际工程中作为自动标注模块使用。本研究前期的数据构建思路正与此类模型高度契合：通过自动生成 caption，再结合人工筛查和风格词修正，使训练数据不仅保留客观内容信息，还能突出“手绘感”“动画电影风格”“暖色光影”等风格特征，为 LoRA 学习提供更明确的监督信号。

## 2.5 视频生成与时序建模技术

### 2.5.1 基于扩散模型的视频生成

视频生成可以看作是图像生成向时间维度的自然扩展，但其难点并不仅仅在于处理更多帧，而在于同时保证单帧质量和跨帧一致性。Video Diffusion Models<sup>[34]</sup> 指出，视频扩散模型可以视为标准图像扩散架构在时空维度上的推广，通过在训练中联合利用图像与视频数据，不仅能够提升生成视频的清晰度与稳定性，还能降低小批量训练时梯度估计的方差，加快优化过程。这说明视频生成并不是完全脱离图像生成而独立存在的任务，而是与图像扩散模型共享大量基础结构与学习机制。

在具体实现层面，视频扩散模型通常需要在网络中显式建模时间维度信息，例如通过三维卷积、时空注意力或帧间特征交互模块，使模型能够感知相邻帧之间的运动变化与语义连续性<sup>[34]</sup>。如果仅把每一帧独立当作图像生成，虽然可以获得较好的单帧质量，但往往会在视频播放时出现闪烁、主体漂移和动作不连贯等问题。因此，时序一致性建模是视频生成区别于图像生成的关键所在。本研究之所以在图像风格 LoRA 之外继续关注视频阶段，就是希望在已有风格学习结果的基础上，进一步分析风格表达与时间稳定性之间的协调关系。

### 2.5.2 AnimateDiff 运动模块

AnimateDiff<sup>[12]</sup>是近年来图像扩散模型向视频生成扩展的代表性方法之一。该方法的核心贡献在于提出了一种可插拔的运动模块，可以在不对每一个个性化图像模型分别进行视频微调的前提下，直接把已有的文本到图像模型激活为动画生成器。其基本思想是：把外观和风格能力交给原有的图像扩散模型处理，把时间动态和运动先验交给单独训练的 motion module 负责。这样一来，研究者就可以在保留 LoRA、DreamBooth 等个性化外观能力的同时，引入统一的时间运动建模能力。

AnimateDiff 还提出了 MotionLoRA，用于以较小成本适配新的镜头类型或运动模式<sup>[9]</sup>。这一思路对本研究具有直接启发意义。因为本研究的重点并不是从零开始训练一个大规模视频基础模型，而是在 Stable Diffusion + LoRA 的图像风格学习框架上，进一步扩展到短视频生成验证。在这种情况下，采用底模负责外观、附加模块负责运动的解耦思路，比全量训练视频模型更符合时间和算力上的现实条件，也更容易形成可复现实验闭环。

## 2.6 可控生成与结构约束技术

### 2.6.1 ControlNet 条件控制机制

当生成任务不仅要求接近某种风格，还要求保持特定结构、姿态或布局时，单纯依靠文本提示词和风格 LoRA 往往是不够的。ControlNet<sup>[14]</sup>针对这一问题提出，在冻结原有扩散模型主干的基础上，增加一组用于接收结构条件的控制分支，并通过零初始化卷积逐步学习如何把边缘、深度、分割图、人体姿态等条件稳定注入到生成过程中。其优点在于既保留了大模型原有的生成能力，又能以较小成本增加外部结构约束，从而显著提升可控生成能力。

对于视频风格生成任务而言，ControlNet 的意义主要体现在两个方面。第一，它能够在角色姿态、场景布局和镜头结构等方面提供更明确的条件约束，从而降低生成过程中的构图漂移；第二，它与 LoRA 之间具有天然的互补关系，LoRA 更偏向纹理风格与视觉属性的学习，而 ControlNet 更偏向几何结构和空间布局的保持<sup>[14]</sup>。因此，在既要保证画风接近目标风格、又要尽量维持主体结构稳定的场景中，二者联合使用往往比单独依赖其中任意一种方法更有效。

### 2.6.2 风格保持与主体一致性问题

在特定风格视频生成任务中，风格保持与主体一致性是两个相互关联、又彼此制约的目标。若过度强调风格迁移，模型可能会牺牲主体结构、动作合理性和跨帧稳定性；若过度强调结构一致性，则可能导致风格表达不足，画面趋于保守。AnimateDiff<sup>[12]</sup>和 ControlNet<sup>[14]</sup>等工作分别从时间运动建模与空间结构控制两个角度对这一问题提供了解法。结合 LoRA 的参数高效微调能力，可以形成一种更符合工程实践的组合式思路：以 LoRA 学习外观风格，以运动模块保证时序连贯，以结构控制模块维持主体姿态和场景布局。

本研究的技术路线正是在这一理论认识基础上逐步展开的。前期先使用 Stable Diffusion 底模与 LoRA 进行图像风格学习，验证特定风格是否能够稳定注入；中期再通过批量推理、图像对比和可视化分析，评估 LoRA 对色彩、构图和风格强度的影响；后期则进一步扩展到视频阶段，考察在加入时序建模与结构控制后，能否在保持画风相似性的同时获得更平滑的动作表现和更稳定的主体特征。由此可以看出，风格保持与一致性控制并不是彼此孤立的模块，而是构成特定风格视频生成系统的两条主线。

## 2.7 本章小结

本章围绕本研究涉及的核心理论与关键技术进行了系统梳理。首先介绍了扩散模型的基本原理以及条件引导机制，明确了当前文生图任务的概率建模基础；其次分析了潜空间扩散模型和 Stable Diffusion 的网络结构，说明了其在高分辨率生成与可控条件注入方面的优势；随后重点阐述了 LoRA 参数高效微调技术及其在扩散模型中的应用方式，解释了本研究为何能够在有限算力条件下完成风格学习实验；最后，从 CLIP/BLIP 数据标注、视频扩散、AnimateDiff 以及 ControlNet 等角度，说明了本研究在数据构建、视频扩展与结构控制方面所依赖的关键技术。

## 3 基于 LoRA 的特定风格视频生成方案设计与实现

### 3.1 任务分析与总体架构设计

#### 3.1.1 研究目标与输入输出定义


本研究旨在构建一套面向特定艺术风格的视频生成实验流程，并在有限算力条件下检验基于 LoRA 的参数高效微调方法能否用于风格学习。结合当前实验安排，研究任务可以分为两个层次：其一是图像风格学习与验证，即使用特定风格图像对 Stable Diffusion 底模进行 LoRA 微调，并结合推理结果、对比图与可视化指标判断风格注入效果；其二是在图像阶段结果的基础上继续做短视频原型验证，通过逐帧递推生成和时序一致性分析，观察该风格适配器在视频场景中的延续表现。

从系统输入输出看，本研究的输入主要包括三部分：原始风格图像及其文本描述、视频阶段使用的帧序列或文本提示词，以及云端实验配置参数，如分辨率、训练步数、LoRA 秩、推理步数和视频帧数等。系统输出包括训练得到的 LoRA 权重文件、单图推理结果、baseline 与 LoRA 的对比图、批量视频片段、时序一致性评估结果，以及实验过程中的配置与统计清单。这样界定后，整套实现流程就可以按同一条实验链路组织，便于复现、扩展和横向比较。

#### 3.1.2 系统整体流程设计

围绕特定风格视频生成任务，本文把系统流程划分为数据准备、模型训练、结果生成和实验评估四个环节。数据准备阶段负责完成原始风格图像的扫描、完整性检查、中心裁剪、尺寸统一、训练验证集划分和文本描述整理；视频部分则补充连续帧的抽样、裁剪缩放与片段级元数据组织。模型训练阶段以 Stable Diffusion 系列模型为预训练底座，在 U-Net 注意力层中注入 LoRA 适配器，并通过最小化噪声预测误差完成风格学习。结果生成阶段包含图像推理、基线模型与 LoRA 模型的横向对比，以及短视频原型生成。实验评估阶段再结合定性观察、图像差异可视化和无参考时序一致性指标，对模型性能进行分析。

从实现顺序看，本文采用先图像、后视频的路线。图像阶段重点解决风格数据组织、LoRA 轻量化微调和风格注入效果验证等问题；视频阶段则在已有图像

风格学习结果的基础上，继续考察连续帧场景下的风格保持与时序稳定性。相关中文综述指出，视频生成在继承图像生成能力的同时，还需要额外处理时间连续性与动态一致性问题<sup>[35]</sup>。考虑到视频扩散模型训练对算力和时间成本要求较高，本文暂时采用基于图像扩散模型的短视频原型方案，通过首帧生成与递推式组合构造短视频片段，用来验证连续生成的可行性。

系统各个环节之间的输入输出关系和执行顺序如图3-1所示。




图 3-1 系统整体流程设计

## 3.2 数据集构建与预处理模块设计

### 3.2.1 风格图像数据集构建

数据集构建是风格学习任务的基础环节。围绕本文的研究目标，图像阶段选取风格较为统一的动画图像作为训练数据来源，并采用与样本同名的文本文件保存 caption 描述。这样处理后，LoRA 模型可以更集中地学习目标画风中的配色、光影、场景构图和笔触特征；同时，成对的图文描述也有助于模型在训练过程中建立风格特征与文本条件之间的联系，提高后续提示词驱动生成的可控性。

为了兼顾训练效率与实验闭环的可复现性，本文没有采用大规模混合风格数据，而是把数据规模控制在适中范围内，并尽量保持样本风格分布一致。每个



样本都由图像和对应文本描述组成一个最小训练单元，从而在数据层面建立“视觉内容—文本语义—风格特征”之间的直接对应关系。这样的组织方式更便于批量处理和人工校验，也能把研究重点放在风格学习效果和生成质量分析上。

### 3.2.2 图像数据预处理与元数据导出

图像预处理模块的任务，是把来源不一、尺寸各异的原始样本转换为适合扩散模型训练的统一输入。具体来说，系统先扫描全部样本并校验可读性，剔除损坏文件；再将有效图像统一转换为 RGB 格式，并采用中心裁剪结合缩放的方式生成固定分辨率训练图像。由于本文重点关注场景与背景风格学习，中心裁剪能够较好保留主景区域，同时避免因输入尺寸不一致造成批处理困难。

在样本划分阶段，系统通过固定随机种子打乱样本顺序，再按照预设比例切分训练集与验证集。这样既能保证每轮预处理结果可重复，也能避免数据按原始命名顺序聚集带来的偏差。与只输出处理后图像的简单脚本相比，本文的预处理模块还会同步导出元数据文件，记录处理后图像标识及其对应文本描述，供训练阶段的数据加载器直接使用。

除训练元数据外，系统还额外保存原始样本到处理样本的映射关系，以及扫描数量、有效数量、训练验证划分结果和 caption 完整性等统计信息。这些记录至少有两点用途：当某一张生成结果异常时，可以快速回溯到原始样本；当需要在论文中说明数据组织过程时，也可以直接引用统计结果，而不必依赖人工估算。对本研究而言，元数据组织本身也是实验可解释性的一部分。

### 3.2.3 视频帧数据预处理设计

考虑到本文的视频部分主要用于原型验证，而不是完整视频底模训练，视频数据的组织目标与图像数据并不完全相同。图像数据更关注风格统计分布是否稳定，视频数据则更关注片段内部的帧序关系和基本可用性。因此，视频预处理模块先以片段为单位读取连续帧，并按帧编号排序，避免时序关系被打乱；再依据最小帧数、最大帧数和采样步长等规则筛选不合格片段，保留能够支撑一致性计算的样本。

在帧级处理上，系统与图像阶段保持一致，同样执行 RGB 转换、中心裁剪和尺寸统一。这样可以保证图像阶段和视频阶段在空间尺度上的一致性，减少后

续递推式  $\text{img2img}$  生成时因输入分辨率变化带来的不稳定因素。与此同时，视频元数据以片段为单位记录帧序列、帧数和对应文本描述，使系统既能将其视为连续序列，也能在需要时回溯到单帧层面。

### 3.3 基于 LoRA 的风格学习模型设计

#### 3.3.1 训练底模与条件输入设计

在模型设计上，本文采用 Stable Diffusion 系列模型作为风格学习底座。这类模型具有较成熟的潜空间扩散架构和文本条件生成能力，适合小样本风格微调任务。训练时，系统先通过 VAE 将输入图像编码为潜变量，再利用文本编码器将 caption 转换为条件语义向量，随后由 U-Net 在给定时间步和文本条件下完成噪声预测。该结构延续了第二章所述潜空间扩散模型的优势，使系统在较高分辨率下仍能保持可接受的显存开销和训练效率。

从条件输入角度看，模型训练以“图像潜变量 + 文本条件 + 时间步编码”为基本输入结构。图像经 VAE 编码到潜空间后，再由文本编码器将 caption 转换为语义向量，U-Net 则在指定扩散时间步上预测噪声残差。文本经过 tokenizer 编码后会被截断或填充到固定长度，以便与图像批量输入一同送入模型。在实现中，系统还保留了 caption dropout 机制，即在一定概率下将文本置空，用来提升模型对弱条件输入的鲁棒性。

#### 3.3.2 LoRA 注入策略与参数配置

LoRA 的基本思想是在冻结原始权重的前提下，用两个低秩矩阵近似原始参数更新量。若某线性层原始权重记为  $W$ ，则引入 LoRA 后的权重可表示为  $W' = W + BA$ ，其中  $A$  和  $B$  为待学习的低秩矩阵。本文在实现中主要将 LoRA 注入到 U-Net 注意力模块的关键投影层，使风格相关的特征重组过程可以通过少量附加参数完成。由于注意力层既参与局部纹理组织，也参与文本条件对齐，因此这一注入位置在风格学习任务中效率较高。

关键参数包括 LoRA 秩、学习率、训练步数、梯度累积步数、分辨率、混合精度模式和检查点保存间隔等。相关综述指出，在预训练-微调范式下，随着模型规模增大，模型适配过程中的硬件要求、数据需求和实际代价都会随之上升<sup>[36]</sup>。其中，LoRA 秩决定适配器容量，秩越高，理论上能够表达更复杂的风格

偏移，但训练开销也会增加；学习率和训练步数共同决定参数更新强度，设置过小时风格不明显，设置过大又容易引起底模固有结构被过度改写。本文在多轮实验中采用统一的基础配置，并围绕训练步数和底模先验展开重点比较，以便把实验差异尽量收敛到少数关键变量上。

为了兼顾显存和训练时间，系统采用小批量训练配合梯度累积的方式实现较高分辨率训练，并启用 fp16 混合精度与 TF32 加速。这些设置并不改变风格学习原理，但会直接影响实验能否顺利跑通，也使多组底模比较与长训实验成为可能。

### 3.3.3 训练目标与优化流程

训练流程沿用标准扩散模型的噪声预测框架。设输入图像经 VAE 编码后得到潜变量  $z_0$ ，在随机时间步  $t$  上加入高斯噪声后形成  $z_t$ ，模型则在文本条件  $c$  的约束下预测噪声项  $\epsilon$ 。其优化目标可以写为公式3-1：

$$L_{\text{diff}} = \mathbb{E}_{z_0, \epsilon, t} \left[ \|\epsilon - \epsilon_{\theta}(z_t, t, c)\|_2^2 \right] \quad (3-1)$$

与全参数训练不同，本文在反向传播阶段仅更新 LoRA 适配器参数，而冻结 VAE、文本编码器和 U-Net 主体权重。这样可以让优化过程集中在风格适配而不是底模重建上，既降低训练成本，也减少样本规模有限时出现过拟合或崩坏的风险。为了保证训练过程稳定，系统同时引入梯度裁剪、阶段性保存和最佳损失记录等机制，使实验既可以中断恢复，也便于比较不同训练阶段对应的生成结果。

需要说明的是，扩散损失下降只表示模型在噪声预测意义上更贴近训练样本分布，并不一定意味着主观风格更优。因此，训练优化流程从一开始就与图像对照和可视化报告模块配套设计。每轮训练结束后，都需要通过统一的推理与对照流程验证效果，而不能只凭损失值判断训练是否成功。

## 3.4 生成与评估模块实现

### 3.4.1 单图推理与基线对比实现

单图推理模块主要用于对训练后权重进行快速验证。系统在加载预训练扩散模型后叠加 LoRA 权重，并在固定提示词、负向提示词、随机种子和采样参数的条件下输出样例图像。该过程既可用于训练后的即时检查，也可用于挑选代表

性场景，观察风格迁移是否已经出现明确方向。为了避免不同轮次推理结果不可重复，系统会同时保存推理参数摘要，使同一组样例能够在后续实验中精确复现。

本文并未停留在单张样例展示上，而是额外实现了批量提示词对照模块。该模块针对统一的场景提示词集合，先用未加载 LoRA 的底模生成 baseline 图像，再在完全相同的种子与参数下加载 LoRA 生成对应结果。在随机性被尽量控制的前提下，baseline 与 LoRA 之间的差异就更容易归因于 LoRA 学到的风格偏移本身。这种批量对照方式提高了实验结论的可靠性，也避免了只凭少量“挑图”得出片面判断。

在系统实现上，批量对照结果会被统一整理为比较清单，记录提示词、图像路径和对应实验参数，为后续可视化脚本提供稳定输入接口。这样一来，图像生成模块就不只是输出图片，同时也是整个结果分析链路的前置环节。

### 3.4.2 短视频生成原型实现

在视频部分，本文没有直接训练完整视频扩散模型，而是采用递推式短视频原型方案。现有中文综述表明，视频任务如果缺乏有效的跨帧信息建模，往往容易出现细节不稳定和时间不连贯现象<sup>[37]</sup>；与此同时，基于扩散模型的视频合成工作也强调了结构条件与内容引导在连续生成中的作用<sup>[38]</sup>。基于此，系统先通过文本到图像管线生成首帧，再把上一帧作为图像到图像管线的输入，在保持提示词主体不变的前提下逐帧生成后续画面，从而构成一段短视频序列。该方案实现成本较低，与已有图像 LoRA 的兼容性也较强，能够在不额外引入庞大视频主干网络的前提下，初步观察风格能力能否向连续帧迁移。

为了提高递推生成的连续性，系统在视频生成时固定基础随机种子、guidance scale、strength 和帧数等关键参数，并分别生成 baseline 视频和 LoRA 视频，保证两者可以进行一一对应比较。这样得到的视频序列既可用于定性观察，也可直接送入后续一致性指标计算模块。

该原型中的帧间递推关系可写为公式3-2，其整体执行逻辑则如图3-2所示。

$$I_0 = G_{\text{txt2img}}(p, n, s), \quad I_t = G_{\text{img2img}}(I_{t-1}, p, n, s + t, \alpha) \quad (3-2)$$




图 3-2 递推式短视频生成原型原理

### 3.4.3 时序一致性评价指标设计

为了对短视频原型结果进行量化分析，系统实现了无参考时序一致性评估模块。与传统图像评价不同，视频评价更关注相邻帧之间的平滑过渡和结构稳定性，因此系统设计了三类基础指标。第一类是相邻帧像素平均绝对差，用于衡量整体画面变化幅度；第二类是基于灰度梯度构造的边缘变化平均绝对差，该指标借鉴了梯度幅值能够敏感反映结构退化与局部边缘变化的思路<sup>[39]</sup>，通过先计算灰度图梯度，再比较相邻帧的边缘幅值差异，反映结构轮廓的稳定程度；第三类是亮度标准差，用于衡量全局亮度在时间维度上的波动情况。这三项指标合在一起，可以对视频时序一致性给出一个基础描述。

设第  $t$  帧图像为  $I_t$ ，边缘图为  $E_t$ ，帧亮度均值为  $Y_t$ ，则本文采用的三个主要指标分别如公式3-3至公式3-5所示：

$$\text{MAD} = \frac{1}{T-1} \sum \text{mean}(|I_t - I_{t-1}|) \quad (3-3)$$

$$\text{MED} = \frac{1}{T-1} \sum \text{mean}(|E_t - E_{t-1}|) \quad (3-4)$$

$$\text{LS} = \text{std}(\{\text{mean}(Y_t)\}) \quad (3-5)$$

其中，MAD 用于描述相邻帧整体变化幅度，MED 用于描述边缘结构稳定

性，LS 用于描述亮度闪烁程度。数值越低，通常意味着帧间过渡越平滑或波动越弱。虽然这组指标不能替代更复杂的视频质量评价体系，但对于当前短视频原型验证已经足够实用，因为它们能够以统一标准比较 baseline 与 LoRA 视频在连续性上的相对变化。

### 3.5 关键算法描述

#### 3.5.1 图像预处理算法

图像预处理算法的目标是在尽量保留样本主体区域的前提下，将原始风格样本变换为统一尺寸的训练输入，并同步导出训练所需的文本元数据与源样本映射。该算法主要包括递归扫描、有效性校验、中心裁剪、固定比例划分和元数据导出几个步骤，重点在于输入规范化和结果可回溯。

其算法流程如算法1所示：

| 算法 1: 图像预处理算法                                  |                                                          |
|------------------------------------------------|----------------------------------------------------------|
| <b>输入:</b> 原始图像目录 $D$ ，目标分辨率 $R$ ，验证集比例 $\rho$ |                                                          |
| <b>输出:</b> 处理后的训练集、验证集及元数据文件                   |                                                          |
| 1                                              | 递归扫描目录 $D$ 中的全部图像文件;                                     |
| 2                                              | 移除损坏或无法读取的图像文件;                                          |
| 3                                              | <b>foreach</b> 有效图像 $x_i$ <b>do</b>                      |
| 4                                              | 裁剪中心正方形区域，并缩放到 $(R, R)$ ;                                |
| 5                                              | 若存在同名文本文件，则读取对应 caption;                                 |
| 6                                              | 使用固定随机种子打乱全部有效样本;                                        |
| 7                                              | 按照比例 $\rho$ 划分得到 $D_{\text{train}}$ 与 $D_{\text{val}}$ ; |
| 8                                              | 导出图像文件、metadata jsonl 及源样本映射关系;                          |

#### 3.5.2 LoRA 训练算法

LoRA 风格学习算法以预训练扩散模型为基础，通过冻结主体参数并仅优化低秩适配器，完成特定风格统计分布的高效迁移。其核心思路是保留底模原有的场景构建能力，同时利用目标风格数据对注意力投影层进行局部重塑，从而在较低训练成本下获得可观测的风格偏移。

其算法流程如算法2所示：

---

**算法 2: LoRA 风格适配训练算法**

---

**输入:** 预训练扩散模型  $M$ , 训练集  $D_{\text{train}}$ , LoRA 秩  $r$   
**输出:** LoRA 权重  $\Delta W$

- 1 冻结 VAE、文本编码器与原始 U-Net 主体参数;
- 2 在注意力投影层中插入 LoRA 适配器;
- 3 **foreach** 训练步骤 **do**
- 4     将图像  $x$  编码为潜变量  $z_0$ ;
- 5     将 caption  $c$  编码为文本嵌入  $h$ ;
- 6     采样时间步  $t$  与高斯噪声  $\epsilon$ ;
- 7     构造带噪潜变量  $z_t$ ;
- 8     预测  $\hat{\epsilon} = \epsilon_\theta(z_t, t, h)$ ;
- 9     计算扩散损失  $L = \|\epsilon - \hat{\epsilon}\|_2^2$ ;
- 10    仅使用 AdamW 更新 LoRA 参数;
- 11 保存 LoRA 权重与训练状态;

---

### 3.5.3 视频递推生成算法

递推式短视频生成算法的出发点, 是在不额外训练视频主干网络的条件下复用图像风格 LoRA 来构造连续帧。其基本策略是先生成首帧, 再以前一帧为条件递推生成后一帧, 借助图像到图像转换保持场景连续性, 并通过统一参数控制使 baseline 与 LoRA 序列具备可比性。

其算法流程如算法3所示:

---

**算法 3: 视频递推生成原型算法**

---

**输入:** 提示词  $p$ , 负向提示词  $n$ , LoRA 适配器  $L$ , 帧数  $T$   
**输出:** 帧序列  $\{I_t\}_{t=0}^{T-1}$

- 1 加载 text-to-image 与 image-to-image 推理管线;
- 2 按需将 LoRA 适配器  $L$  注入两条推理管线;
- 3 通过 text-to-image 管线生成首帧  $I_0$ ;
- 4 **for**  $t \leftarrow 1$  **to**  $T - 1$  **do**
- 5     将上一帧  $I_{t-1}$  作为输入图像;
- 6     在强度参数  $\alpha$  下通过 image-to-image 管线生成  $I_t$ ;
- 7 保存全部帧, 并组合为 GIF 或视频清单文件;

---

## 3.6 本章小结

本章围绕系统设计与实现过程, 说明了本文实验链路的具体组织方式。前半部分介绍了研究目标、总体架构、数据构建和预处理流程, 交代了训练数据与视频片段如何完成规范化组织; 后半部分则集中讨论基于 Stable Diffusion 系列模型的 LoRA 风格学习设计, 以及图像推理、批量对照、短视频生成原型和时序一

致性评估模块的实现方式。通过这些内容可以看出，本文的研究工作已经落实为一套可复现的实验系统，也为第四章的实验与结果分析提供了实现基础。



## 4 实验与结果分析

### 4.1 实验设置

#### 4.1.1 实验目标与验证思路

本章围绕特定动画风格视频生成任务，主要讨论四个问题：数据整理与训练流程是否稳定可靠；基于 LoRA 的参数高效微调能否在有限样本条件下学到较明确的风格特征；不同底模先验是否会明显影响风格迁移的方向与强度；图像阶段获得的风格能力能否延续到短视频原型中，并在一定程度上改善跨帧一致性。围绕这些问题，实验设计采用“短训验证、长训加强、底模替换、视频原型扩展”的递进路线，使每一阶段都有对应结论，后续实验也能够建立在前一阶段可复现的结果之上。

图像阶段先以 Stable Diffusion 1.5 为基础模型完成 300 步短训实验，用来验证 768 分辨率训练、LoRA 注入和批量推理链路能否稳定运行。随后，在主体流程不变的前提下，继续调整 caption 组织方式和训练步数，观察风格强化策略是否会带来更明显的手绘动画表现。考虑到风格生成任务不仅受训练数据影响，也明显受到底模视觉先验的制约，本文进一步引入更偏故事书插画风格的 StorybookRedmond，以及具有较强二次元先验的 Counterfeit-V3.0 作为替代底模，以考察不同底模对目标风格适配效果、结构保真度和生成可控性的影响。

在实验方法上，所有图像对比都尽量控制提示词、随机种子、采样步数和输出分辨率一致，并通过统一脚本完成 baseline 与 LoRA 结果的并行生成。这样处理后，观察到的差异就更可能来自 LoRA 权重与底模组合本身，而不是推理噪声或人工挑选样例造成的偶然偏差。视频阶段则延续先图像、后视频的思路，不直接训练大规模视频扩散模型，而是在图像风格 LoRA 的基础上构建递推式短视频生成原型，通过无参考时序一致性指标评估相邻帧变化是否更平滑、边缘结构是否更稳定，以及亮度闪烁是否得到抑制。

#### 4.1.2 数据集与预处理结果

图像风格学习阶段采用整理后的吉卜力动画风格图像数据集作为训练基础。经过扫描与预处理后，共得到 810 张样本，其中有效样本 810 张，没有损坏或无

法读取的样本；按 9:1 的比例划分后，训练集为 729 张，验证集为 81 张。所有样本均配有同名文本描述文件，因此 caption 覆盖率达到 100%，这为后续文本条件训练提供了较一致的输入基础。由于本研究并不追求大规模通用模型训练，而是强调特定风格的定向学习，因此数据集规模被控制在中等水平，使单轮实验能够在有限时间内完成闭环。

在预处理过程中，全部图像统一转换为 RGB 格式，并执行中心裁剪、比例规整和尺寸缩放，以消除原始采集源中普遍存在的宽高差异和边缘留白问题。实验分辨率统一设置为 768×768，这一设置兼顾了画面细节、显存占用与训练效率。

视频阶段的数据主要用于流程验证与一致性分析，而不是大规模视频底模训练。当前共整理出 5 个片段样本，其中训练片段 4 个、验证片段 1 个，累计导出 100 帧。进一步的交叉检查表明，训练集与验证集片段之间不存在编号重叠，数据泄漏计数为 0，说明划分过程满足基本的独立性要求。另一方面，图像推理阶段还预先定义了 10 条场景提示词，覆盖港口、街道、铁路、桥梁、卧室、山村、森林小径和河边集市等典型动画场景，为统一的横向比较提供了稳定的测试集合。

数据集规模、划分比例和 caption 覆盖情况的汇总结果如表4-1所示。

表 4-1 数据集预处理与划分结果

| 数据类型    | 扫描数量 | 有效数量 | 训练集 | 验证集 | caption<br>数量 | 缺失<br>caption | 说明               |
|---------|------|------|-----|-----|---------------|---------------|------------------|
| 图像风格数据集 | 810  | 810  | 729 | 81  | 810           | 0             | 统一处理为 768×768    |
| 视频片段数据集 | 5    | 5    | 4   | 1   | 5             | 0             | 累计导出 100 帧，无数据泄漏 |

4.1.3 实验环境与参数配置

实验训练环境采用基于 Conda 管理的独立虚拟环境，以避免不同模型依赖冲突对实验结果造成干扰。整个实验过程均在 Linux 系统下运行，训练框架以 PyTorch、Diffusers、Transformers、Accelerate 和 PEFT 为核心，形成了较稳定的扩散模型微调工作流。具体硬件与软件环境如表4-2所示。

表 4-2 实验硬件与软件环境

| 项目           | 配置                      | 说明                      |
|--------------|-------------------------|-------------------------|
| GPU          | NVIDIA RTX 3080 Laptop  | 承担 768 分辨率 LoRA 训练与批量推理 |
| 操作系统         | Linux 5.15.0-78-generic | 实验脚本运行环境                |
| Python       | 3.10.8                  | 核心运行时                   |
| PyTorch      | 2.11.0+cu130            | 深度学习训练框架                |
| Diffusers    | 0.27.2                  | 扩散模型加载与推理框架             |
| Transformers | 4.39.3                  | 文本编码与模型组件支持             |
| Accelerate   | 0.28.0                  | 训练加速与混合精度支持             |
| PEFT         | 0.10.0                  | LoRA 参数高效微调支持           |

训练参数在多轮实验中基本保持一致：图像分辨率固定为 768，训练批量大小为 1，梯度累积步数为 2，学习率统一为  $1e-04$ ，LoRA 秩设为 16，并启用 fp16 混合精度与 TF32 加速。由于本章关注的是不同底模和训练策略对风格学习的影响，而不是追求某一模型的极限拟合，因此参数设计强调公平与可重复。Stable Diffusion 1.5 主线实验允许更长训练步数，StorybookRedmond 和 Counterfeit-V3.0 则采用相同的 1200 步设置，以便观察不同底模先验在相近训练强度下的表现差异。各组训练方案的核心配置如表4-3所示。

表 4-3 主要训练方案配置

| 实验名称                | 底模                             | 最大训练步数 | 分辨率 | LoRA 秩 | 学习率    | caption dropout |
|---------------------|--------------------------------|--------|-----|--------|--------|-----------------|
| SD1.5 短训            | runwayml/stable-diffusion-v1-5 | 300    | 768 | 16     | $1e-4$ | 0.05            |
| caption 强化短训        | runwayml/stable-diffusion-v1-5 | 300    | 768 | 16     | $1e-4$ | 0.05            |
| caption 强化长训        | runwayml/stable-diffusion-v1-5 | 2000   | 768 | 16     | $1e-4$ | 0.05            |
| StorybookRedmond 长训 | Yntec/StorybookRedmond         | 1200   | 768 | 16     | $1e-4$ | 0.00            |
| Counterfeit-V3.0 长训 | danbrown/Counterfeit-v3-0      | 1200   | 768 | 16     | $1e-4$ | 0.00            |

推理阶段同样遵循控制变量原则。单图与批量对比均固定随机种子和场景提示词，仅在是否加载 LoRA、使用何种底模以及采样参数细节上进行调整。总体上，Stable Diffusion 1.5 主线实验的推理步数略高于替代底模，以保证其在较中性的底模先验下仍能获得足够的去噪时间；StorybookRedmond 和 Counterfeit-V3.0

则适当降低采样步数与 `guidance scale`，以减少过强引导带来的图像硬化与局部失真。视频原型实验在此基础上进一步引入固定帧数、强度参数和帧率设置，使不同组视频的一致性指标具备横向比较的条件。

#### 4.1.4 评价指标与结果呈现方式

为了避免仅凭主观印象判断风格学习效果，本文将训练过程指标、图像对比指标和视频一致性指标结合起来进行分析。训练阶段记录 `global step` 与 `best loss`，用于反映 LoRA 适配器在去噪目标上的收敛情况；但需要说明的是，扩散模型训练损失只反映噪声预测误差，并不能直接等价于“更接近吉卜力风格”或“视觉效果更好”。因此，本章在解释 `loss` 变化时始终将其与后续图像结果、差异图和定量对比表放在一起考察，避免用单一训练曲线替代最终质量判断。

图像阶段的核心定量指标包括像素平均绝对差、亮度变化、对比度变化、饱和度变化和边缘强度变化。像素平均绝对差用于衡量加载 LoRA 后图像整体发生了多大程度的变化，其数值越大，通常说明 LoRA 对底模输出的干预越强；但这一指标只能说明变化幅度，不能直接说明这种变化一定朝着目标风格优化。亮度、对比度和饱和度等指标则有助于进一步分析风格偏移的方向，例如更柔和的手绘动画风格往往伴随色彩压缩和局部边缘处理的变化，而边缘强度变化可以辅助判断画面轮廓是否趋向平滑。

视频阶段使用无参考的一致性指标来衡量跨帧稳定性。`MAD` 描述相邻帧像素差异的平均水平，数值越低通常表示帧间过渡更平滑；`MED` 描述相邻帧边缘结构差异，数值越低通常表示结构变化更稳定；`LS` 描述全局亮度均值的标准差，数值越低通常表示亮度闪烁更弱。由于本研究的视频部分仍处于原型验证阶段，尚未引入 `FVD` 等更复杂的时空评测指标，因此 `MAD`、`MED` 与 `LS` 在这里更多提供趋势性证据，用来判断图像阶段训练得到的风格 LoRA 是否对短视频连续性有正向帮助。

## 4.2 图像风格学习实验结果分析

### 4.2.1 基于 Stable Diffusion 1.5 的短训验证结果

首先考察基于 Stable Diffusion 1.5 的 300 步短训结果。该实验的 `best loss` 为 0.001998，像素平均绝对差为 0.111979。从数值上看，LoRA 已经能够对底模输

出产生可观察的风格干预，但干预程度仍保持在相对温和的范围内。这与短训实验的定位是一致的：它的主要任务不是追求最强烈的风格迁移，而是确认在新的云端算力平台上，数据预处理、LoRA 注入、训练、推理和对比可视化能否构成稳定闭环。

从汇总指标看，该轮实验的亮度变化为 0.0152，对比度变化为-0.0090，饱和度变化为-0.0537，边缘强度变化为-0.0070。这些指标表明，LoRA 并未简单地把图像推向极端高饱和或极端高对比方向，而是在颜色分布、线条强度和局部结构上进行了相对克制的重塑。从工程角度看，这种变化有限但方向明确的状态说明训练链路是有效的，同时也提示仅靠 300 步训练还不足以充分放大目标风格特征。

对应的典型 baseline 与 LoRA 可视化样例如图4-1所示。




图 4-1 基于 Stable Diffusion 1.5 短训结果的 baseline 与 LoRA 对比样例

从典型样例可以看到，加载 LoRA 后的图像在构图、建筑分布和前景元素上与 baseline 存在明显差异，说明模型已经不只是微调局部色彩，而是开始影响场景的组织方式。与此同时，图像整体仍保持了较高的可读性和场景完整性，没有出现大范围语义崩坏。这说明短训 LoRA 在本任务中具有较好的冒烟验证价值：它能够较快证明风格学习是可行的，并为后续更长训练和更换底模提供可靠起点。

进一步观察图4-2所示的 10 条提示词差异分布，可以发现不同场景对风格 LoRA 的敏感度并不一致。例如，包含复杂建筑群、前景栏杆或交通元素的提示

词往往产生更大的像素差异，这说明风格学习并不是均匀作用于整张图像，而会优先改变更能承载手绘笔触与空间层次的区域。这一结果至少说明两点：LoRA 已经具备一定的场景适应能力；后续实验也不能只看单一样例，而应结合多场景统计结果来判断风格学习是否稳定。



图 4-2 Stable Diffusion 1.5 短训实验在 10 条提示词上的差异指标分布

#### 4.2.2 caption 组织增强实验分析

在完成基础短训验证后，本文尝试通过轻量化的 caption 风格增强策略进一步放大目标风格信号。其出发点是，如果文本描述能够在内容信息之外加入更统一的风格表述，模型可能会更快学习到手绘动画的色调、背景表现和镜头氛围。然而实验结果表明，这一策略并未稳定带来正向收益。300 步 caption 强化短训的像素平均绝对差为 0.106736，略低于基础短训的 0.111979，说明在短步数条件下，额外的 caption 风格表述并没有显著增强风格注入强度，反而可能在一定程度上削弱了底模对场景语义的自由组织。

当训练步数增加到 2000 步后，caption 强化长训的 best loss 下降到 0.001930，像素平均绝对差上升到 0.147990，相较于基础短训提高了 32.16%。如果只看训练损失和整体变化幅度，这一结果似乎意味着模型学到了更强的风格偏移能力；但结合实际样例与单提示词统计可以发现，变化增强并不等价于质量提升。部分

场景在长训后出现了更明显的构图重排、主体位置漂移和局部细节失衡，尤其是包含轨道、车体、远景透视线或复杂建筑排列的提示词，更容易出现与原始语义布局不完全一致的情况。

这一现象说明，过度依赖统一化 caption 风格描述，可能会使模型在训练中更倾向于追逐风格标签的表面特征，而弱化对具体场景语义的细致响应。对于扩散模型而言，caption 本质上是条件约束的一部分。若文本中过多重复统一风格短语，而样本规模又有限，模型就容易把这些高频词与某些固定色块、构图模板或光照模式绑定，最终在推理阶段表现为风格更强但可控性下降。换句话说，caption 强化实验提供了一条很重要的负面经验：在样本规模不大的前提下，训练目标应优先保证内容与风格之间的平衡，而不是单纯追求风格词堆叠。

因此，caption 组织增强实验虽然在数值上带来了更大的风格差异，但从“接近目标风格且保持场景可读性”这一综合目标出发，它并不是最优方案。该实验的意义主要在于验证了一点：针对特定风格的 LoRA 训练，文本描述质量固然重要，但统一强化并非越强越好，过度一致的文本模板可能压缩样本本身的内容多样性，进而使生成结果趋向模板化。

#### 4.2.3 不同底模长训结果比较

在确认主线流程可用之后，本文进一步将同一数据集接入不同底模，考察底模先验对目标风格学习的影响。如表4-4所示，比较对象包括 Stable Diffusion 1.5 主线结果、StorybookRedmond 长训结果和 Counterfeit-V3.0 长训结果。

表 4-4 各组图像训练结果统计

| 实验名称                | global step | best loss | 像素平均绝对差  | 亮度变化   | 对比度变化   | 饱和度变化   | 边缘强度变化  |
|---------------------|-------------|-----------|----------|--------|---------|---------|---------|
| SD1.5 短训            | 300         | 0.001998  | 0.111979 | 0.0152 | -0.0090 | -0.0537 | -0.0070 |
| caption 强化长训        | 2000        | 0.001930  | 0.147990 | 0.0134 | -0.0012 | -0.0150 | -0.0088 |
| StorybookRedmond 长训 | 1200        | 0.001994  | 0.197670 | 0.0047 | -0.0117 | -0.0898 | -0.0001 |
| Counterfeit-V3.0 长训 | 1200        | 0.001902  | 0.225164 | 0.0090 | -0.0288 | -0.0241 | 0.0055  |

三者的 best loss 分别为 0.001998、0.001994 和 0.001902。如果仅从 loss 角度看，Counterfeit-V3.0 的收敛值最低，似乎更容易被数据集驱动；但结合图像对比



指标可以看到，底模之间的差异并不能只用“是否更容易收敛”来判断。

从整体变化幅度看，StorybookRedmond 长训的像素平均绝对差达到 0.197670，相较于 Stable Diffusion 1.5 短训提高了 76.52%；Counterfeit-V3.0 长训则达到 0.225164，提升幅度达到 101.08%。这说明具有更强动画插画或二次元先验的底模，确实更容易在少量 LoRA 微调之后形成明显的风格偏移。对于追求风格变化强度的实验目标而言，这样的底模更有优势，因为它们本身就位于更接近目标分布的视觉空间中，LoRA 只需在原有先验上进行定向修正即可。StorybookRedmond 对应的典型对比样例如图4-3所示。




图 4-3 StorybookRedmond 长训结果的 baseline 与 LoRA 对比样例

但从具体样例可以进一步看到，底模先验增强的同时也会带来新的问题。StorybookRedmond 在若干场景中能够更快形成柔和、插画感较强的色面组织，使画面更接近童话绘本或动画海报的视觉风格；然而它也更容易重写原始构图关系。例如在海港、街巷等需要明显透视关系的场景中，局部建筑朝向、远景层次和水面空间感有时会被简化为更平面化的组织方式。也就是说，StorybookRedmond 的风格表达更积极，但在维持提示词内容的几何可解释性方面未必优于更中性的 Stable Diffusion 1.5。

如图4-4所示，Counterfeit-V3.0 的表现则更为鲜明。该底模在轮廓线、色块边界和二次元角色化视觉语言上具有更强先验，因此加载 LoRA 后的变化最为剧烈，部分样例呈现出明显的动漫化重绘倾向。其优点在于风格冲击力强、轮廓表达清晰，适合快速生成具有动画感的画面；缺点则在于目标风格会被更广义的二



次元审美所稀释，导致结果更接近泛动漫插画，而不一定稳定落在“温润、背景绘画感较强”的吉卜力式区域。尤其在港口、河道和街区等场景中，Counterfeit-V3.0 更容易出现大尺度构图重排和结构关系改写，这在一定程度上削弱了提示词与图像之间的对应精度。




图 4-4 Counterfeit-V3.0 长训结果的 baseline 与 LoRA 对比样例

综合来看，不同底模之间不存在绝对单一的最优解，而是体现出明显的目标差异。若实验更关注风格偏移强度，StorybookRedmond 与 Counterfeit-V3.0 的长训结果显然比 Stable Diffusion 1.5 更激进；若实验更关注风格注入与场景保真之间的平衡，则 Stable Diffusion 1.5 虽然变化幅度较小，却保留了更高的可控性和更稳定的场景语义响应。

#### 4.2.4 图像阶段结果归纳

将以上实验放在同一框架下，可以得到较清晰的结论。首先，基于 810 张风格图像、768 分辨率和 LoRA 参数高效微调的训练路线是可行的，图像实验已经从“能否跑通”进入“如何平衡风格强度与内容保真”的阶段。其次，训练损失下降和像素差异增大虽然能够说明模型对数据集的适配程度在上升，但这并不自动代表结果更接近目标风格，仍需要结合场景可读性和主观观感综合判断。再次，caption 统一强化和更换强先验底模都可以放大风格迁移强度，但前者容易造成模板化，后者容易引入底模固有审美偏差，因此都需要在可控性和目标风格纯度之间做权衡。

## 4.3 视频原型实验与时序一致性分析

### 4.3.1 视频原型实验方案

考虑到专门视频扩散模型训练的成本远高于图像 LoRA 微调，本文在视频阶段采用递推式短视频生成原型进行验证。具体做法是先依据文本提示词生成首帧，再将上一帧作为下一帧的输入，通过固定 strength、采样步数和随机种子递推得到一段短视频片段。该方案不需要额外训练庞大的视频主干网络，能够在已有图像风格 LoRA 的基础上直接观察手绘动画风格是否能够延续到连续帧中，因此适合作为当前阶段的原型验证路线。

实验中首先选取 10 条具有代表性的场景提示词用于统一的图像对比，其中 5 条提示词被进一步用于 12 帧短视频的批量生成评估；在此基础上，又额外抽取 2 条提示词进行云端复核，以验证结果趋势是否稳定。视频生成的主要参数包括固定帧数、固定种子基数、固定 guidance scale 和固定强度系数，保证 baseline 视频与加载 LoRA 后的视频具有一一对应关系。这样，指标变化就可以更明确地反映 LoRA 对跨帧连续性的影响，而不是采样配置变化造成的噪声。

从数据组织角度看，视频预处理阶段共整理出 5 个可用片段并导出 100 帧样本，这为后续设计训练-验证片段划分、检查数据泄漏以及实现基本一致性度量提供了基础。尽管现阶段的视频样本规模较小，不足以支撑完整的时空生成模型训练，但已经足以作为图像风格能力向连续帧迁移的证据来源。

### 4.3.2 时序一致性定量结果

短视频原型在不同评估集合上的时序一致性指标汇总如表4-5所示。

表 4-5 短视频原型时序一致性指标对比

| 评估集合    | Baseline MAD | LoRA MAD | MAD 变化 | Baseline MED | LoRA MED | MED 变化 | Baseline LS | LoRA LS | LS 变化   |
|---------|--------------|----------|--------|--------------|----------|--------|-------------|---------|---------|
| 5 组批量实验 | 0.13879      | 0.12986  | -6.43% | 0.06252      | 0.06086  | -2.65% | 0.01675     | 0.01872 | +11.72% |
| 2 组复核实验 | 0.13898      | 0.13642  | -1.84% | 0.06290      | 0.05993  | -4.71% | 0.00817     | 0.00880 | +7.77%  |

从表4-5中的 5 组批量实验结果看，加载 LoRA 后的视频在 MAD 指标上由 0.138789 下降到 0.129858，降幅约为 6.43%；MED 指标由 0.062519 下降到 0.060861，降幅约为 2.65%。这说明在当前递推式视频生成方案下，图像阶段训练得到的风格 LoRA 确实能够在一定程度上降低相邻帧之间的整体变化与边缘结构突变，使画面过渡更平滑，结构抖动有所缓解。

但在亮度稳定性方面，LS 指标从 0.016752 上升到 0.018716，增幅约为 11.72%。也就是说，LoRA 版本虽然在画面连续性和结构稳定性上略有改善，却没有同步抑制全局亮度闪烁，反而使亮度均值波动有所增加。结合生成机制可以推测，这是因为递推式 img2img 方案在每一帧都会重新执行带噪去噪过程，LoRA 对色彩与光照风格的强化会在帧间逐步积累，从而把原本较弱的亮度变化放大为可测量的全局波动。

表4-5中的 2 组复核实验进一步验证了这一趋势。复核结果中，LoRA 版本的 MAD 由 0.138983 降至 0.136421，MED 由 0.062896 降至 0.059934，对应降幅分别为 1.84% 和 4.71%；与此同时，LS 仍从 0.008172 上升到 0.008806。尽管复核样本数量较少，但与批量实验呈现出相同方向的变化，说明“结构连续性改善而亮度稳定性不足”的结论具有一定稳定性，而不是个别样例造成的偶然现象。

从指标解释的角度看，这组结果也符合当前原型方案的技术特征。递推式生成的优势在于，它天然以上一帧为条件，因此能够较好保留颜色分区、主体轮廓和背景布局的局部延续性；但不足也很明显，它缺乏真正的视频时序建模模块，无法显式学习全局运动轨迹、镜头规律和长期亮度约束。因此，只要连续帧中的局部扰动不断累积，就可能在颜色层面产生轻微漂移或整体曝光起伏。图像风格能力已经开始向连续帧迁移，但距离成熟的视频扩散系统仍有明显差距。

### 4.3.3 视频结果的定性观察与局限

结合实际生成的短视频片段可以进一步看到，LoRA 对连续帧的作用主要体现在前几帧，表现为画面整体色调、天空与建筑色块的组织方式更趋统一，局部笔触和边缘线条也更符合目标风格。但随着递推步数增加，误差会逐帧积累，某些片段会出现局部区域变形、纹理重复、结构轻微漂移甚至主体边界模糊等现象。尤其是在场景中存在水面反光、栏杆、轨道、电线杆或密集屋顶时，这类高频结构对递推生成更为敏感，容易在不断重绘中产生形态抖动。

这说明图像阶段训练得到的 LoRA 权重虽然能够提供风格方向上的约束，但不能替代显式的时序建模。换句话说，LoRA 解决的是“每一帧更像目标风格”的问题，而视频生成还需要额外解决“每一帧之间如何保持运动与结构连续”的问题。当前实验已经证明，单帧风格能力向视频序列迁移是可行的，但要进一步提升亮度稳定性、主体一致性和长序列可控性，仍需要引入专门面向视频的运动先验、光流约束或跨帧特征交互机制。

尽管如此，视频原型实验仍然具有明确的研究价值。首先，它使本文中的技术路线形成了完整闭环，即从图像数据构建、LoRA 风格学习、图像推理对比，一直延伸到连续帧的原型验证；其次，它给出了定量证据，说明图像 LoRA 对短视频的结构平滑性存在一定正向影响；最后，它也比较准确地暴露出当前方案的瓶颈所在，为后续改进提供了清晰方向。

## 4.4 实验讨论

### 4.4.1 风格学习有效性讨论

综合图像与视频实验结果可以看出，本文采用的“中等规模风格图像数据集 + Stable Diffusion 系列底模 + LoRA 参数高效微调 + 批量对比评估”这一方案是能够跑通并产生有效结果的。数据预处理阶段保证了图像与文本描述的对应关系，减小了训练条件中的噪声；LoRA 训练阶段则以较小的参数规模完成了风格迁移；后续的批量推理和可视化分析，也为结果比较提供了比较稳定的依据。

实验也表明，影响目标风格学习效果的，不只是训练步数长短，更关键的是数据、文本描述和底模先验之间能否对得上。当预训练模型原有生成分布与目标风格本身距离较远时，即便训练过程比较稳定，LoRA 也往往只能做出有限的风格修正<sup>[40]</sup>；而当底模已经带有较强的动画先验时，模型又可能把结果进一步推向更宽泛的二次元视觉分布。换句话说，在特定风格生成任务里，底模并不是一个可以忽略的背景条件，而是会直接影响实验结论的重要变量。

### 4.4.2 指标与主观观感差异的原因分析

本章实验中有一个现象比较明显：有些实验虽然训练损失下降了，或者像素差异变大了，但主观观感并没有跟着变好。原因并不复杂。首先，扩散模型优化的是噪声预测误差，而不是直接去优化风格相似度，所以 loss 下降只能说明模型

更贴近当前训练数据的统计分布，不能直接说明生成结果一定更美观，或者更接近目标风格。其次，像素平均绝对差这类指标反映的是变化幅度，而不是变化本身的好坏；变化变大，既可能意味着风格注入更充分，也可能意味着语义偏移、构图重排或局部失真。再者，风格任务本身就带有较强的审美判断色彩，最终还是需要结合图像样例来一起看。

以 caption 强化长训为例，这一组实验的 loss 和差异幅度都优于基础短训，但实际结果并没有形成更稳定的目标风格，反而在部分提示词下出现了过度强化和模板化的问题。再看 Counterfeit-V3.0，虽然它在数值上表现出最明显的风格偏移，但这种偏移并不能简单理解为吉卜力风格更强，因为模型同时把更重的泛动漫先验也带了进来。由此可以看出，在风格生成实验里，定量指标更适合用来观察趋势、发现问题和支持比较；真正的结论，还是要把定量分析、可视化样例和任务目标放在一起判断。

#### 4.4.3 当前方案的局限与后续优化方向

当前实验仍然存在几方面局限。其一，图像数据集规模虽然已经能够支撑 LoRA 风格学习，但样本覆盖面仍然有限，特别是在人物、复杂镜头和强运动场景上分布不足，这会限制模型对更丰富场景的泛化能力。其二，视频阶段尚未采用真正意义上的直接训练大规模视频扩散模型，因此跨帧一致性的提升幅度有限，亮度闪烁问题也没有得到根本解决。其三，评价体系仍以无参考指标和人工观察为主，缺少更系统的图文一致性、感知质量和时序质量评价指标。

基于以上局限，后续优化可以从三个方向展开。首先，在数据层面继续扩充风格样本，并对 caption 做更细粒度的语义约束，而不是简单叠加统一风格词汇，以提高内容保持与风格强化之间的平衡性。其次，在模型层面引入更适合视频任务的结构，如 AnimateDiff 类运动模块、跨帧注意力机制或 ControlNet 条件约束，以降低长序列递推中出现的结构漂移和亮度抖动。再次，在评测层面增加 CLIP 相似度、感知距离以及更成熟的视频一致性指标，使结果分析更加全面。

总体来看，当前研究已经完成了从图像风格学习到短视频原型验证的关键链路搭建，并在多轮实验中积累了可直接写入论文的数据与现象。虽然距离完整、高质量的视频生成系统仍有差距，但本章实验已经足以说明所提出的技术路线具备可行性，并为后续继续完善模型、数据和评测体系打下了基础。

## 4.5 本章小结

本章围绕实验设置、图像风格学习结果、短视频原型实验和综合讨论,对系统进行了较完整的实验性验证。结果表明:在 810 张风格图像和 768 分辨率设置下,基于 LoRA 的参数高效微调能够有效学习目标风格特征,并在多场景提示词上产生稳定可观测的风格偏移;不同底模对结果影响显著,其中 StorybookRedmond 与 Counterfeit-V3.0 可带来更强的风格迁移,但也更容易引入构图重写和底模先验偏差;递推式视频原型实验显示,加载 LoRA 后的短视频在帧间平滑性和结构稳定性上有一定改善,但亮度闪烁仍需进一步优化。这些结论既验证了本文技术路线的可行性,也为下一章的总结与展望提供了实验依据。

## 5 总结与展望

### 5.1 工作总结

本文围绕基于 LoRA 技术的特定风格视频生成模型展开研究。针对当前视频生成领域普遍存在的训练成本高、特定风格定制困难以及时序一致性难以保持等问题，本文提出并验证了一条从图像风格学习到短视频原型验证的技术路线。

本文系统分析了扩散模型、潜空间扩散框架以及 LoRA 的基本原理，明确了在有限算力资源下，利用 LoRA 对 U-Net 注意力模块进行局部重塑，是实现特定风格迁移的一条高效途径。同时，结合 AnimateDiff 等时序建模思想，本文确立了先进行外观学习、再开展时序验证的递进式研究策略。

针对目标动画风格，本文构建了包含 810 张图像和 5 组视频片段的实验数据集。预处理阶段主要完成了中心裁剪、尺寸统一和人工校验等工作，以尽量保证训练样本在风格上的一致性；同时为图像样本配套整理了成对的 caption，为模型提供相对稳定的条件引导信号。

本文以 Stable Diffusion 1.5 为基础模型，通过比较 300 步短训与 2000 步长训的结果，验证了整条训练链路能够稳定运行。随后又引入 StorybookRedmond 和 Counterfeit-V3.0 等具有不同视觉先验的底模进行替换实验。实验结果说明，动画先验更强的底模，往往能在像素平均绝对差等指标上表现出更明显的风格迁移能力，但与此同时，也更容易把自身固有的审美倾向带入结果，并对原有构图关系造成改写。

由于显式视频训练的成本较高，本文采用递推式短视频生成方案进行了原型验证。量化结果表明，加载 LoRA 后的视频在 MAD 和 MED 指标上分别改善了约 6.43% 和 2.65%，这说明图像阶段学到的风格能力确实能够在一定程度上延续到连续帧中。不过，LS 指标仍增加了约 11.72%，这也说明当前方案在亮度稳定性方面还有比较明显的不足。

## 5.2 研究展望

尽管本文在低成本特定风格视频生成方面取得了一定进展，但受限于算力条件和实验周期，现有工作仍有不少可以继续深入的地方。后续研究可以从以下几个方向展开。

1. 引入显式的时序建模模块。当前视频原型主要依赖递推式生成，对运动轨迹和跨帧长程依赖的刻画还不够。后续可以考虑把训练好的风格 LoRA 与 AnimateDiff 运动模块，或更复杂的时空注意力机制进行更深入的结合，从生成机制层面缓解亮度闪烁和主体一致性不足的问题。

2. 增强结构可控性与泛化能力。实验中可以看到，风格注入较强时，有时会破坏原始构图。后续可引入 ControlNet 等条件控制技术，利用边缘图或深度图对生成过程施加几何约束，在保持风格特征的同时，更好地保留主体结构和镜头关系。

3. 完善多维度评估体系。目前使用的 MAD、MED、LS 等指标主要反映像素层面的稳定性。后续还应引入更贴近视觉感知的评价标准，例如衡量图文匹配程度的 CLIP Score、衡量视频感知质量的 FVD，以及更细粒度的风格相似度人工评测方案，从而形成更完整的视频生成评价体系。



## 参考文献

- [1] HO J, JAIN A, ABBEEL P. Denoising Diffusion Probabilistic Models[J/OL]. Advances in Neural Information Processing Systems, 2020, 33: 6840-6851. DOI: 10.48550/arXiv.2006.11239.
- [2] SINGER U, POLYAK A, HAYES D, et al. Make-A-Video: Text-to-Video Generation without Labeled Video Data[EB/OL]. 2022. DOI: 10.48550/arXiv.2209.14792.
- [3] HU E J, SHEN Y, WALLIS P, et al. LoRA: Low-Rank Adaptation of Large Language Models[C]//International Conference on Learning Representations. 2022.
- [4] ROMBACH R, BLATTMANN A, LORENZ D, et al. High-Resolution Image Synthesis with Latent Diffusion Models[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 10684-10695.
- [5] VILLEGAS R, BABAEIZADEH S, KINDERMANS P J, et al. Phenaki: Variable Length Video Generation from Conditioning Texts[C]//International Conference on Learning Representations. 2023.
- [6] DHARIWAL P, NICHOL A. Diffusion Models Beat GANs on Image Synthesis [J]. Advances in Neural Information Processing Systems, 2021, 34: 8780-8794.
- [7] BLATTMANN A, DOCKHORN T, KULAL S, et al. Stable Video Diffusion: Scaling Latent Video Diffusion Models to Large Datasets[EB/OL]. 2023. DOI: 10.48550/arXiv.2311.15127.
- [8] BAR-TAL O, CHEFER H, TOWFIGHI O, et al. Lumiere: A Space-Time Diffusion Model for Video Generation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024.
- [9] RUIZ N, LI Y, JAMPANI V, et al. DreamBooth: Fine-Tuning Text-to-Image Diffusion Models for Subject-Driven Generation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 22500-22510.

- [10] GAL R, ALALUF Y, ATZMON Y, et al. An Image is Worth One Word: Personalizing Text-to-Image Generation Using Textual Inversion[C]//International Conference on Learning Representations. 2023.
- [11] WU J Z, GE Y, WANG X, et al. Tune-A-Video: One-Shot Tuning of Image Diffusion Models for Text-to-Video Generation[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 7623-7633.
- [12] GUO Y, YANG C, RAO A, et al. AnimateDiff: Animate Your Personalized Text-to-Image Diffusion Models without Specific Tuning[C]//International Conference on Learning Representations. 2024.
- [13] CHEN H, XIA M, HE Y, et al. VideoCrafter1: Open Diffusion Models for High-Quality Video Generation[EB/OL]. 2023. DOI: 10.48550/arXiv.2310.19512.
- [14] ZHANG L, RAO A, AGRAWALA M. Adding Conditional Control to Text-to-Image Diffusion Models[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 3836-3847.
- [15] HU L, GAO T, LIAO Z, et al. Animate Anyone: Consistent and Controllable Image-to-Video Synthesis for Character Animation[EB/OL]. 2023. DOI: 10.48550/arXiv.2311.17117.
- [16] BLATTMANN A, ROMBACH R, OKTAY K, et al. Retrieval-Augmented Diffusion Models[J]. Advances in Neural Information Processing Systems, 2022, 35: 15309-15324.
- [17] MOU C, WANG X, XIE L, et al. T2I-Adapter: Learning Adapters to Dig out Prior Knowledge of Text-to-Image Diffusion Models[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023.
- [18] XING Z, DAI Q, HU H, et al. SimDA: Simple Diffusion Adapter for Efficient Video Generation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024.

- [19] UNTERTHINER T, VAN STEENKISTE S, KURACH K, et al. Towards Accurate Generative Models of Video: A New Metric and Challenges[EB/OL]. 2018. DOI: 10.48550/arXiv.1812.01717.
- [20] WANG J, YUAN H, CHEN D, et al. ModelScope Text-to-Video Technical Report [EB/OL]. 2023. DOI: 10.48550/arXiv.2308.06571.
- [21] GAL R, ALALUF Y, ATZMON Y, et al. An Image is Worth One Word: Personalizing Text-to-Image Generation Using Textual Inversion[EB/OL]. 2022. DOI: 10.48550/arXiv.2208.01618.
- [22] QI C, CUN X, ZHANG Y, et al. FateZero: Fusing Attentions for Zero-Shot Text-Based Video Editing[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 8281-8291.
- [23] RADFORD A, KIM J W, HALLACY C, et al. Learning Transferable Visual Models from Natural Language Supervision[C]//Proceedings of the 38th International Conference on Machine Learning. PMLR, 2021: 8748-8763.
- [24] SCHUHMANN C, BEAUMONT R, VENCU R, et al. LAION-5B: An Open Large-Scale Dataset for Training Next Generation Image-Text Models[J]. Advances in Neural Information Processing Systems, 2022, 35: 25278-25294.
- [25] RONNEBERGER O, FISCHER P, BROX T. U-Net: Convolutional Networks for Biomedical Image Segmentation[C]//Medical Image Computing and Computer-Assisted Intervention. Cham: Springer, 2015: 234-241.
- [26] VASWANI A, SHAZEER N, PARMAR N, et al. Attention Is All You Need[J]. Advances in Neural Information Processing Systems, 2017, 30.
- [27] SOHN K, RUIZ N, LEE K, et al. StyleDrop: Text-to-Image Generation in Any Style[EB/OL]. 2023. DOI: 10.48550/arXiv.2306.00983.
- [28] HEUSEL M, RAMSAUER H, UNTERTHINER T, et al. GANs Trained by a Two Time-Scale Update Rule Converge to a Local Nash Equilibrium[J]. Advances in Neural Information Processing Systems, 2017, 30.

- [29] ZHANG R, ISOLA P, EFROS A A, et al. The Unreasonable Effectiveness of Deep Features as a Perceptual Metric[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2018: 586-595.
- [30] CHU M, XIE Y, MAYER J, et al. Learning Temporal Coherence via Self-Supervision for GAN-Based Video Generation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 5833-5842.
- [31] HO J, SALIMANS T. Classifier-Free Diffusion Guidance[EB/OL]. 2022. DOI: 10.48550/arXiv.2207.12598.
- [32] LI J, LI D, XIONG C, et al. BLIP: Bootstrapping Language-Image Pre-training for Unified Vision-Language Understanding and Generation[C]//Proceedings of the 39th International Conference on Machine Learning. PMLR, 2022.
- [33] LI J, LI D, SAVARESE S, et al. BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models[C]//Proceedings of the 40th International Conference on Machine Learning. PMLR, 2023.
- [34] HO J, SALIMANS T, GRITSENKO A, et al. Video Diffusion Models[EB/OL]. 2022. DOI: 10.48550/arXiv.2204.03458.
- [35] 郑屹, 黄向, 秦菲儿, 等. 2D/3D 生成式人工智能技术发展及创意产业应用[J/OL]. 中国图象图形学报, 2025, 30(6): 1953-1984. DOI: 10.11834/jig.250005.
- [36] 殷炯, 张哲东, 高宇涵, 等. 视觉语言预训练综述[J/OL]. 软件学报, 2023, 34(5): 2000-2023. DOI: 10.13328/j.cnki.jos.006774.
- [37] 江俊君, 程豪, 李震宇, 等. 深度学习视频超分辨率技术综述[J/OL]. 中国图象图形学报, 2023, 28(7): 1927-1964. DOI: 10.11834/jig.220130.
- [38] ESSER P, CHIU J, ATIGHEHCHIAN P, et al. Structure and Content-Guided Video Synthesis with Diffusion Models[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 7346-7356.

- [39] XUE W, ZHANG L, MOU X, et al. Gradient Magnitude Similarity Deviation: A Highly Efficient Perceptual Image Quality Index[J/OL]. IEEE Transactions on Image Processing, 2014, 23(2): 668-695. DOI: 10.1109/TIP.2013.2293423.
- [40] CHEN S, PAN Z, CAI J, et al. PaRa: Personalizing Text-to-Image Diffusion via Parameter Rank Reduction[EB/OL]. 2024. DOI: 10.48550/arXiv.2406.05641.

## 致谢

时光如梭，自我初次踏入珞珈山以来已经过去了四年，不知不觉间，我的本科生涯即将告一段落。回顾这四年，无数画面如潮水一般涌入我的脑海，从大一步入校园时在学长学姐组成的迎新志愿者的带领下初识校园，到大二时，我也成为了其中的一员，再到大三时，忙碌于难度陡增的课程与应接不暇的竞赛，再到如今，大四的我提笔写下毕业论文的最后章节。在这四年的校园生活里发生了太多太多，我相信这段美好的记忆将会伴随我的一生，每每道来，感慨万千。在此，我想首先感谢母校的培养，感谢武汉大学为我提供了一个自由成长的平台，自强弘毅、求是拓新的校训将会永远回荡在我的心间！

这一路走来，我遇到了许许多多给过我帮助与鼓励的老师。我要感谢我的毕业设计与论文的指导老师——武宇老师，武老师在我的选题与研究方向上给予了充分的指导，当我面对着庞大的选题一筹莫展时，他为我指明了方向；他还事无巨细地对我的毕业论文进行指导、批注，一步步地帮助我进行论文的撰写与完善。我还要感谢我的班级导师——方颖老师，她总是悉心关注着我们班级中的每一位同学，即使忙得不可开交，还是会挤出时间来到我们宿舍与我们交流学习与生活中的方方面面；在我遇到困难时，她主动向我伸出援手，为我提供了许多宝贵的建议，帮助我顺利完成了推免。

我要感谢这四年来结识的好友与同学。感谢我的室友，我们在学习、竞赛与娱乐中成长，每次的合作与交流都让我收获颇丰；感谢天协中的每一位大朋友与小朋友，我们因浩瀚的宇宙而相会，一同仰望星空，脚踏实地；感谢计算机5班中的每一位同学，这四年来学习与生活因为有了你们而更加精彩。他年若忆同窗事，樽前一笑是年华。别离在即，愿我们有缘再见！

我要感谢我的家人，感谢你们从小到大的陪伴、支持与理解。感谢自初高中起相识至今的好友们。感谢这二十多年的岁月里给过我帮助的所有人。

最后，感谢论文的评审专家对我的论文进行评审，同时感谢答辩老师们能够耐心听我完成答辩并对我的论文给出修改意见。

山水一程，三生有幸。纵使毕业，我也永是珞珈一少年！

